04.03.2026

MACHINE LEARNING

Project Break II - ML

Financial Time Series

Autores: Blanca García, Lucia Luzuriaga y Alejandro Balaguer

ÍNDICE

1. Problema de Negocio
2. Planteamiento técnico
3. Dataset y MiniEDA
4. Modelado y resultados
5. Conclusiones

01

Problema de negoocio

Dataset

```
df = pd.read_csv("../data_sample/NASDAQ100_Historical_Data.csv")
df
```

	Ticker	Date	Open	High	Low	Close	Adj Close	Volume
0	AAPL	2000-01-03	0.94	1.00	0.91	1.00	0.84	535796800
1	AAPL	2000-01-04	0.97	0.99	0.90	0.92	0.77	512377600
2	AAPL	2000-01-05	0.93	0.99	0.92	0.93	0.78	778321600
3	AAPL	2000-01-06	0.95	0.96	0.85	0.85	0.71	767972800
4	AAPL	2000-01-07	0.86	0.90	0.85	0.89	0.75	460734400
...	...	...	...	...	...	...	...	...
514070	ZS	2026-02-11	175.62	175.87	165.36	171.00	171.00	2670100
514071	ZS	2026-02-12	171.99	173.99	163.00	170.90	170.90	2499300
514072	ZS	2026-02-13	174.34	179.90	172.43	177.72	177.72	2434100
514073	ZS	2026-02-17	175.82	176.85	169.61	172.59	172.59	2038100
514074	ZS	2026-02-18	167.35	172.65	164.39	172.13	172.13	2541300

514075 rows × 8 columns

Este dataset contiene:

- Varias empresas del NASDAQ 100
- Datos desde 2000 al 2026
- Variables típicas de mercado: open, close, high, low...

Problema real

Contexto

Las empresas y analistas financieros necesitan anticipar comportamiento futuro del mercado para realizar mejores decisiones

Problema

La predicción manual es limitada y no capta bien patrones complejos ni se adapta a cambios rápidos del mercado

Impacto

- Riesgo en decisiones de inversión
- Dificultad para optimizar carteras
- Falta de herramientas basadas en históricos reales

Oportunidad

Un modelo de ML puede aprender patrones temporales y relaciones entre precios y volumen para poder realizar predicciones más robustas.

02

Planteamiento Técnico

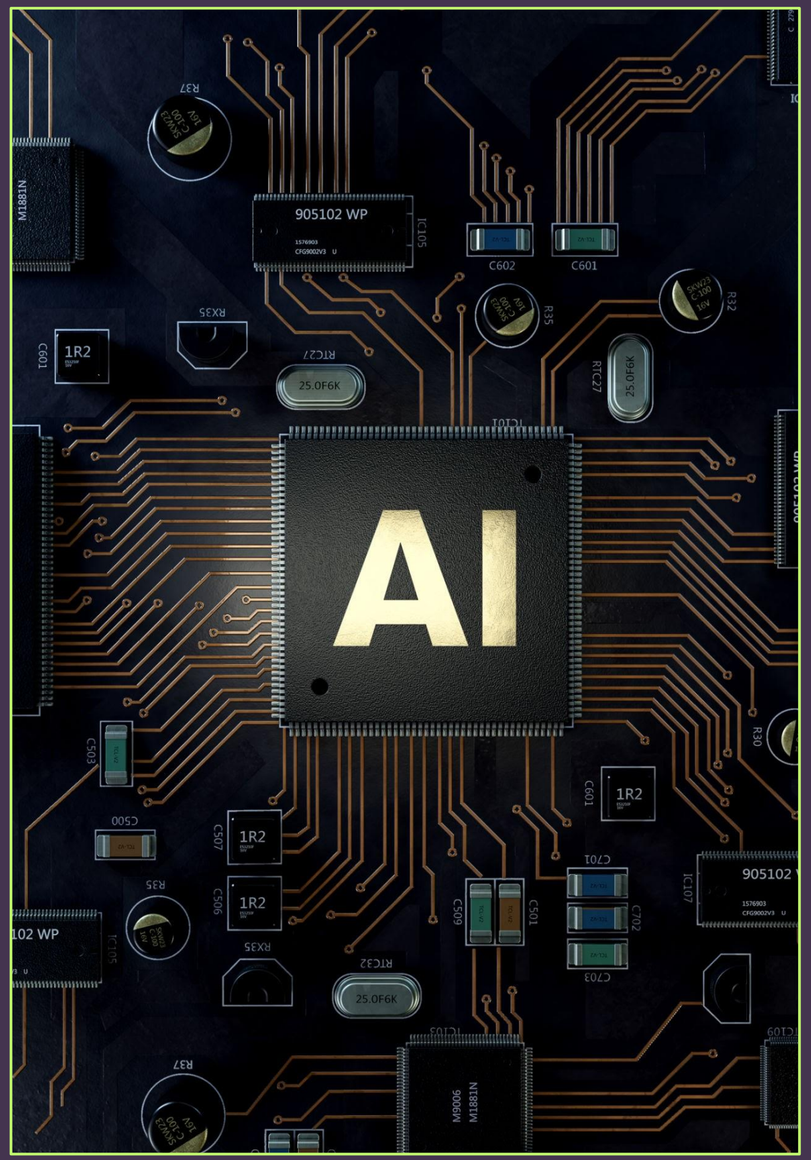

Visión General

Objetivo técnico: Crear un modelo de ML capaz de aprender patrones temporales en los precios de las empresas para así predecir el comportamiento futuro del mercado.

Enfoque:

- Modelado de series temporales
- Predicciones basadas en variables del dataset
- Uso de modelo de clasificación

Beneficio del ML

Captura bien relaciones no lineales y se adapta mejor que reglas fijas

Pipeline

1. **Ingesta de datos**
   Leer el dataset y filtrar por ticker
2. **Preprocesado**
   Convertir, ordenar, eliminar escalar y crear features.
3. **División temporal dataset**
   Separar los años para cada parte del modelo, entrenamiento, validación y test.
4. **Entrenamiento del modelo**
   Probar los modelos para ver cual es el mejor.
5. **Evaluación**
   Comparar métricas y resultados para ver la calidad del modelo

03

Dataset y MiniEDA

EDA

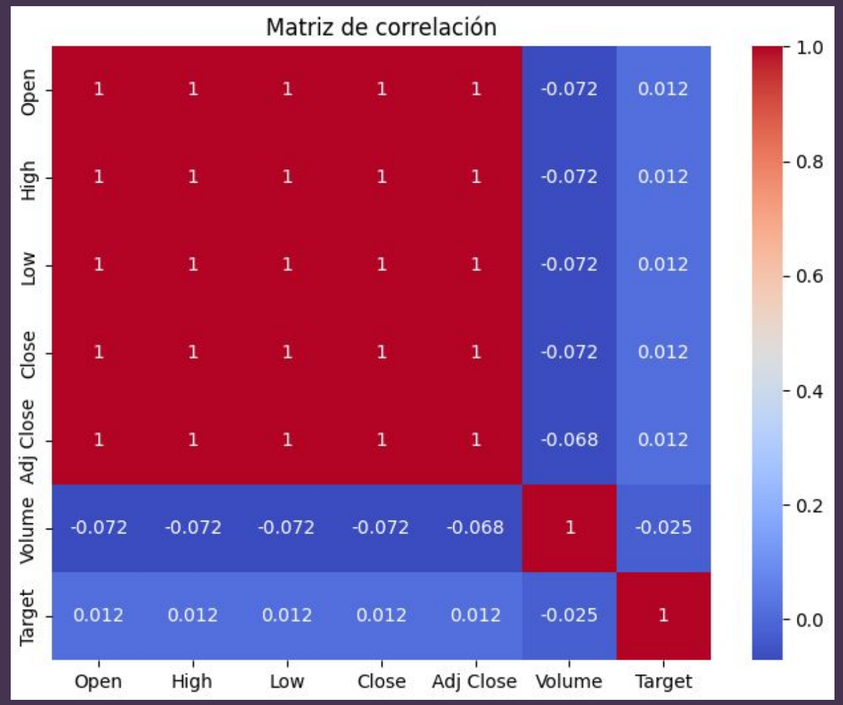

Visualización de outliers

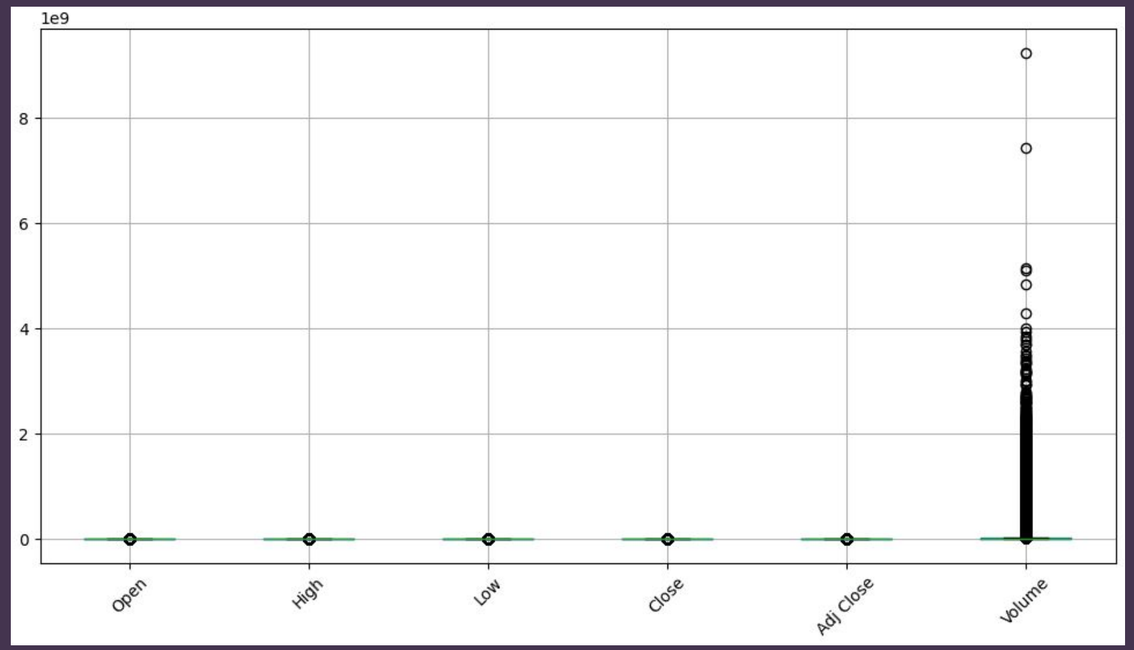

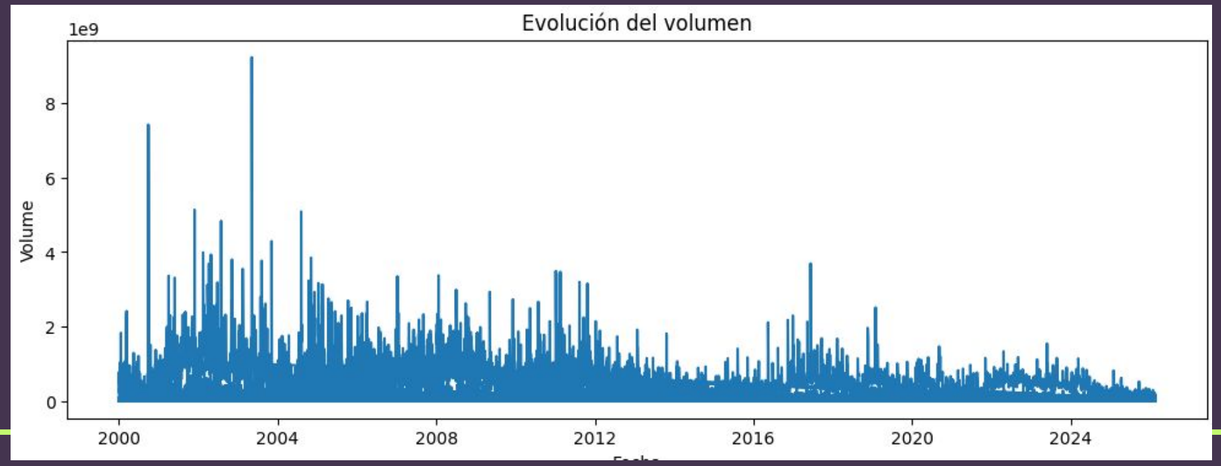

04

Modelado y Resultados

Filtrado de Características

El exceso de variables genera “ruido” matemático y sobreajuste. Para solucionarlo, aplicamos un filtro de multicolinealidad eliminando variables con un correlación >95%.

Luego, usamos un algoritmo Random Forest para puntuar el impacto real de las supervivientes. El resultado: nos quedamos exclusivamente con las 15 variables ganadoras.

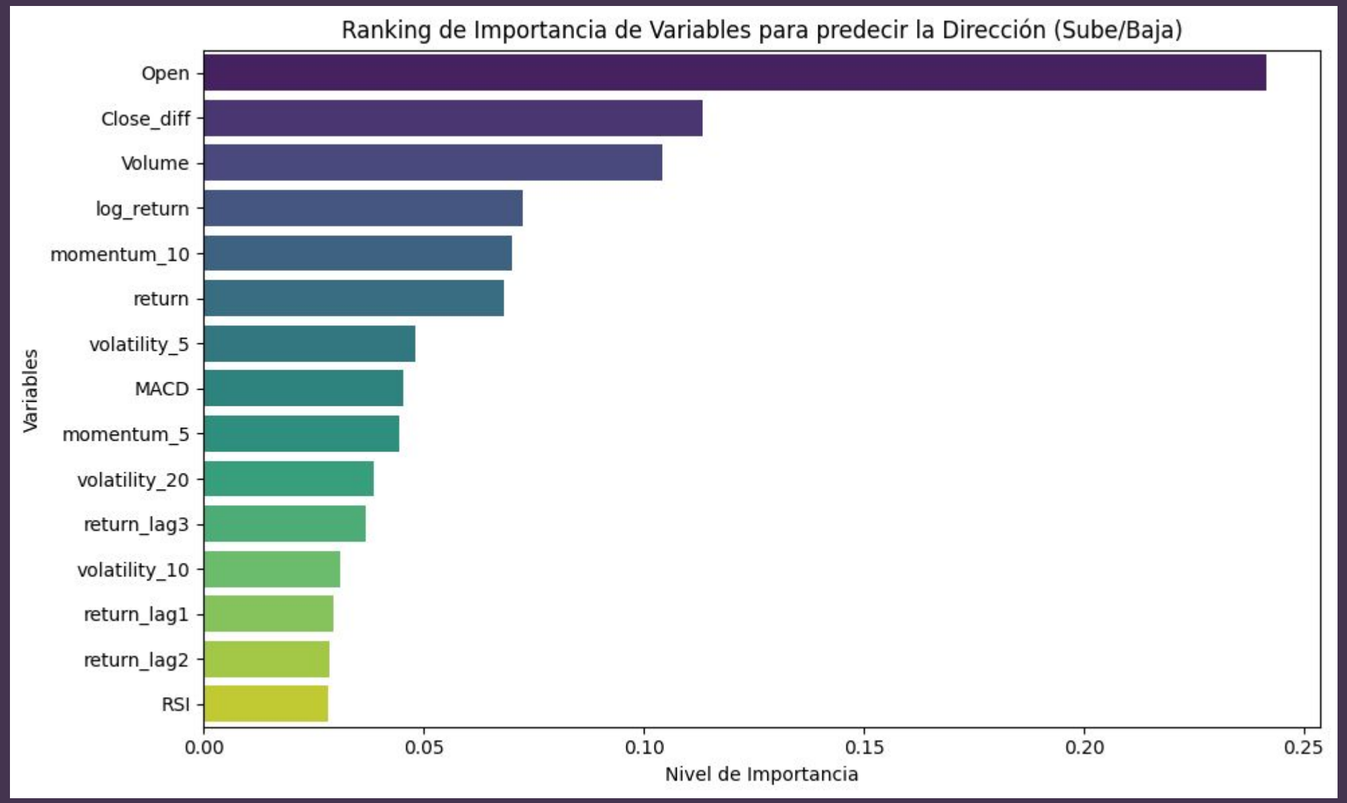

Definición de las métricas de evaluación

Precisión

En el mundo financiero, el "Acierto Global" es engañoso. Nos enfocamos en la Precisión para asegurar que cuando el modelo grita "Compra".

Recall & F1-Score

El Recall mide la sensibilidad: ¿Cuántas subidas reales logramos detectar? El F1-Score nos proporciona un único valor que busca el equilibrio perfecto entre ser conservadores y no perder el coste de oportunidad.

ROC-AUC

Evalúa la capacidad pura del modelo para rankear y distinguir los días alcistas de los bajistas, basándose en la probabilidad.

Selección de los modelos predictivos

Regresión Logística

Actúa como nuestro Baseline o modelo base. Es un algoritmo clásico y rápido que traza fronteras simples.

Random Forest

Un modelo sumamente robusto frente a datos ruidosos.

XGBoost

El estado del arte en predicción de datos tabulares. Su potencia radica en que aprende de forma iterativa.

Optimización de hiperparámetros

- Se ajustaron los hiperparámetros del modelo para mejorar su rendimiento.
- Se utilizaron técnicas de búsqueda como Grid Search o Random Search.
- El objetivo fue encontrar la combinación que maximiza el rendimiento del modelo.

Ejemplo de hiperparámetros optimizados:

- ➔ n_estimators
- ➔ max_depth
- ➔ learning_rate
- ➔ subsample
- ➔ colsample_bytree

Modelo final

- Tras la optimización, el modelo con mejor rendimiento fue XGBoost:

```
Mejor modelo: XGBoost
Métrica: auc = 0.5085798845960208
```

- Este modelo mostró mejor capacidad para capturar patrones complejos del mercado.

Hiperparámetros finales:

```
modelo_xgb = xgb.XGBClassifier(
    n_estimators=300,
    learning_rate=0.05,
    max_depth=6,
    subsample=0.8,
    colsample_bytree=0.8,
    objective='binary:logistic',
    eval_metric='logloss',
    random_state=42,
    n_jobs=-1
)
```

Resultado del modelo: XGBoost

Accuracy	0.5106646028640129
Precision	0.5149469000219903
Recall	0.7571561709492743
F1-score	0.6129931323334668
ROC-AUC	0.5083073938924216

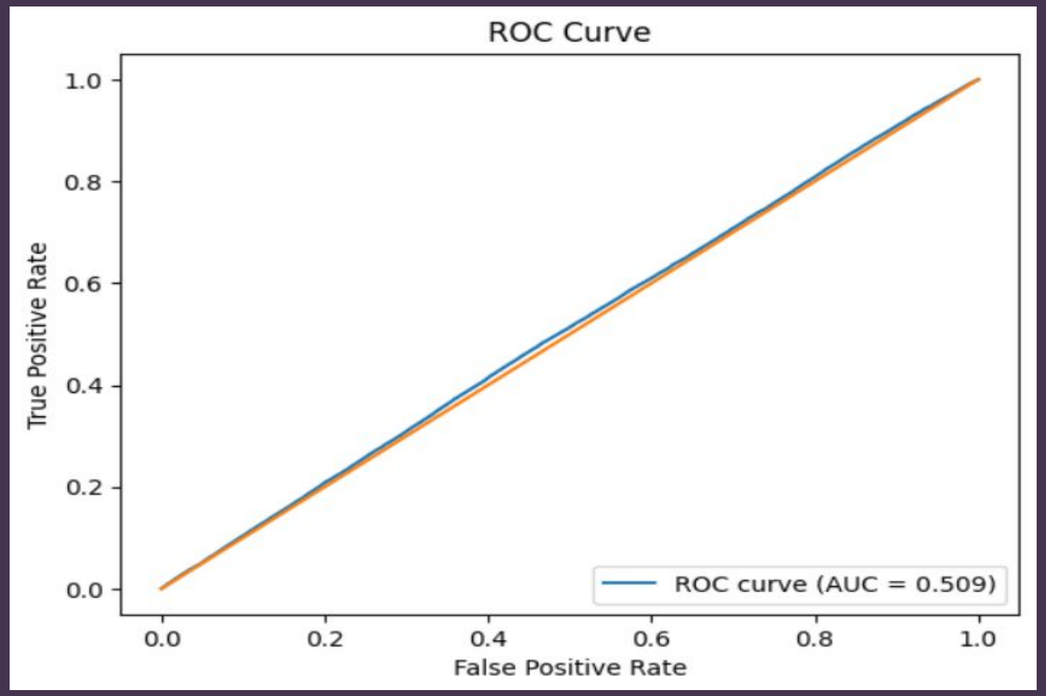

El modelo se evaluó en un conjunto de test separado para medir su capacidad de generalización.

05

Conclusiones

Conclusiones

Los modelos de ensemble, como XGBoost, mostraron mejor rendimiento.

El feature engineering fue clave para mejorar las predicciones.

El modelo logra capturar patrones en el comportamiento del mercado.

Mejora futura

Incluir más indicadores financieros

Usar más datos históricos

Aplicar validación temporal más avanzada